Analisis Performa Breadth-First Search (BFS) Paralel pada GPU Berdasarkan Representasi Graph

Ahmad Raihannudin Yahya
Faculty of Artificial Intelligence and Data Science
Universitas Pelita Harapan
Jakarta, Indonesia
01085230010@student.uph.edu

Daniel Christofer Marvel
Faculty of Artificial Intelligence and Data Science
Universitas Pelita Harapan
Tangerang, Jakata
01085230012@student.uph.edu

Ferry Yoshua Sanaky
Faculty of Artificial Intelligence and Data Science
Universitas Pelita Harapan
Tangerang, Jakata
01085230010@student.uph.edu

Ilhand Aby Riano
Faculty of Artificial Intelligence and Data Science
Universitas Pelita Harapan
Tangerang, Jakata
01085210010@student.uph.edu

Kalena Yves Adiwinanda
Faculty of Artificial Intelligence and Data Science
Universitas Pelita Harapan
Tangerang, Jakata
01085230014@student.uph.edu

Matthew Kurniawan
Faculty of Artificial Intelligence and Data Science
Universitas Pelita Harapan
Tangerang, Jakata
01087230002@student.uph.edu

Breadth-First Search (BFS) merupakan algoritma traversal graph yang banyak digunakan, namun kurang efisien untuk data berukuran besar jika dijalankan secara sekuensial. Pemanfaatan GPU memungkinkan percepatan melalui komputasi paralel, tetapi performa sangat dipengaruhi oleh representasi struktur data graph.

Penelitian ini menganalisis performa BFS paralel pada GPU dengan membandingkan tiga representasi graph, yaitu Edge List, Compressed Sparse Row (CSR), dan Coordinate Format (COO). Evaluasi dilakukan berdasarkan waktu eksekusi kernel dan transfer memori.

Hasil menunjukkan bahwa CSR memberikan performa terbaik, diikuti COO, sementara Edge List memiliki performa paling rendah. Hal ini menunjukkan bahwa pemilihan representasi graph berpengaruh signifikan terhadap efisiensi BFS paralel pada GPU.

Kata kunci: BFS, GPU, komputasi paralel, representasi graph

I. Introduction

Graph merupakan struktur data yang banyak digunakan untuk merepresentasikan hubungan antar entitas dalam berbagai bidang, seperti analisis jaringan sosial, sistem rekomendasi, dan pemrosesan data skala besar. Salah satu algoritma traversal graph yang umum digunakan adalah Breadth-First Search (BFS), yang bekerja dengan menjelajahi node secara bertingkat berdasarkan jarak dari node sumber. Namun, seiring dengan meningkatnya ukuran dan kompleksitas data graph, implementasi BFS secara sekuensial menjadi kurang efisien karena keterbatasan dalam pemanfaatan sumber daya komputasi.

Untuk mengatasi permasalahan tersebut, pendekatan komputasi paralel mulai banyak digunakan, khususnya dengan memanfaatkan Graphics Processing Unit (GPU) yang mampu mengeksekusi ribuan thread secara simultan. Pemanfaatan GPU dapat meningkatkan performa BFS secara signifikan, terutama pada graph berukuran besar. Meskipun demikian, performa BFS paralel tidak hanya ditentukan oleh algoritma yang digunakan, tetapi juga sangat dipengaruhi oleh representasi struktur data graph di dalam memori.

Berbagai representasi graph seperti Edge List, Compressed Sparse Row (CSR), dan Coordinate Format (COO) memiliki karakteristik dan pola akses memori yang berbeda. Perbedaan ini berpengaruh langsung terhadap efisiensi penggunaan memori dan kinerja eksekusi pada arsitektur GPU. Pola akses memori yang tidak optimal dapat menyebabkan penurunan performa meskipun tersedia paralelisme yang tinggi.

Oleh karena itu, penelitian ini bertujuan untuk menganalisis performa BFS paralel pada GPU dengan membandingkan beberapa representasi graph. Evaluasi dilakukan berdasarkan waktu eksekusi dan overhead transfer memori untuk mengidentifikasi representasi yang paling efisien dalam konteks komputasi paralel berbasis GPU.

II. Ease of Use

Kemudahan penggunaan (ease of use) dari representasi graph dianalisis berdasarkan kompleksitas implementasi, kebutuhan preprocessing, serta kemudahan integrasi dengan algoritma BFS paralel.

Representasi adjacency list berbasis array (forward star) memiliki kompleksitas implementasi yang relatif tinggi. Struktur ini memerlukan pengelolaan beberapa array, yaitu head, to, dan next, yang digunakan untuk merepresentasikan hubungan antar edge. Pendekatan ini melibatkan mekanisme pointer chaining berbasis indeks, sehingga meningkatkan kompleksitas dalam proses konstruksi dan pemeliharaan data.

Representasi Compressed Sparse Row (CSR) memiliki kompleksitas moderat. Struktur ini memerlukan tahap preprocessing untuk membangun array row_ptr dan col_idx, namun menghasilkan representasi yang terorganisir dan efisien. CSR banyak digunakan dalam komputasi paralel karena mendukung pola akses memori yang terstruktur dan mudah diintegrasikan dengan kernel GPU [3], [5].

Representasi Coordinate Format (COO) merupakan yang paling sederhana dalam hal implementasi. Graph direpresentasikan sebagai pasangan edge dalam dua array, yaitu row dan col, tanpa memerlukan struktur tambahan. Pendekatan ini mempermudah proses konstruksi dan manipulasi data, namun tidak menyediakan pengelompokan tetangga secara eksplisit, sehingga kurang optimal untuk traversal berbasis node.

Secara keseluruhan, COO memiliki tingkat kemudahan penggunaan tertinggi karena kesederhanaan strukturnya, diikuti oleh CSR yang menawarkan keseimbangan antara struktur dan kompleksitas, sedangkan adjacency list berbasis array memiliki kompleksitas implementasi paling tinggi.

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

III. METHODOLOGY

A. Experimental Environment

Eksperimen dalam penelitian ini dilakukan menggunakan platform Google Colaboratory yang menyediakan akses ke GPU. GPU yang digunakan adalah NVIDIA Tesla T4, yang mendukung komputasi paralel dengan jumlah thread yang besar. Lingkungan eksperimen meliputi:

- Platform: Google Colab
- GPU: NVIDIA Tesla T4
- Bahasa Pemrograman: C/CUDA
- Tools: NVIDIA CUDA Toolkit dan Nsight Systems

B. Datasets

Dataset yang digunakan dalam penelitian ini diambil dari platform Kaggle, yaitu dataset graph web-NotreDame yang tersedia pada Stanford Large Network Dataset Collection (SNAP) [1]. Dataset ini merepresentasikan struktur jaringan web dengan total 325,728 node dan sejumlah edge yang merepresentasikan hubungan antar halaman web.

Untuk menganalisis pengaruh ukuran graph terhadap performa algoritma, dataset dibagi menjadi beberapa subset dengan ukuran bertahap. Subset dibuat mulai dari 5,000 node dan ditingkatkan secara bertahap sebesar 5,000 node pada setiap iterasi hingga mendekati ukuran maksimum dataset. Secara keseluruhan, dilakukan sekitar 66 variasi ukuran dataset.

Pendekatan ini bertujuan untuk mengevaluasi skalabilitas algoritma BFS paralel serta mengamati perubahan performa seiring dengan bertambahnya ukuran graph.

C. Graph Representation

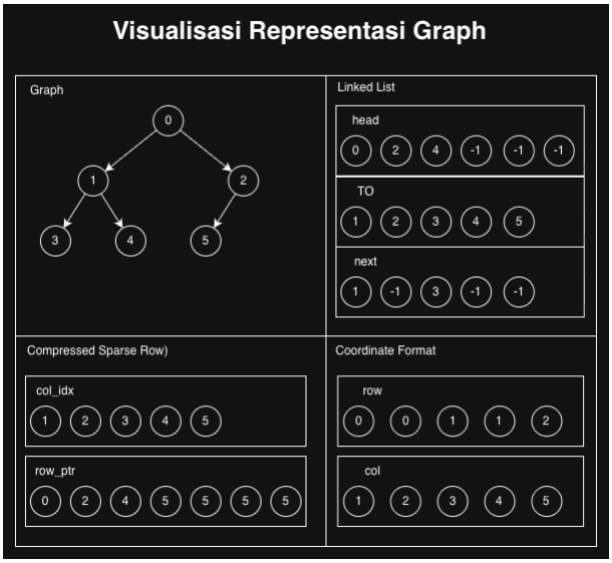

Tiga representasi graph yang digunakan dalam penelitian ini adalah sebagai berikut:

- Adjacency List (Forward Star Representation).

  Representasi ini menggunakan pendekatan adjacency list yang diimplementasikan dalam bentuk array, yang terdiri dari tiga komponen utama yaitu head, to, dan next. Array head menyimpan indeks edge pertama untuk setiap node, sedangkan array to menyimpan node tujuan dari setiap edge. Array next digunakan untuk menghubungkan edge-edge yang berasal dari node yang sama, sehingga membentuk struktur linked list secara implisit di dalam array.

  Untuk setiap node u, seluruh tetangga dapat diakses dengan memulai dari head[u], kemudian mengikuti indeks next hingga mencapai nilai -1. Struktur ini memberikan fleksibilitas dalam penyimpanan graph, namun menghasilkan pola akses memori yang tidak berurutan.

- Compressed Sparse Row (CSR)

  CSR merepresentasikan graph menggunakan dua array utama, yaitu row_ptr dan col_idx. Array row_ptr menunjukkan batas awal dan akhir dari daftar tetangga untuk setiap node, sedangkan col_idx menyimpan node tetangga secara berurutan.

  Struktur ini memungkinkan akses memori yang terorganisir dan sekuensial, sehingga sangat cocok untuk arsitektur GPU yang mengandalkan efisiensi bandwidth memori.

- Coordinate Format (COO)

  COO menyimpan graph dalam bentuk pasangan koordinat edge menggunakan dua array, yaitu row dan col. Setiap pasangan (row[i], col[i]) merepresentasikan satu edge dalam graph.

  Meskipun lebih sederhana dibanding CSR, COO tidak memiliki struktur indeks yang mengelompokkan tetangga berdasarkan node, sehingga pola akses memori menjadi kurang optimal.

D. Parallel BFS Implementation

Algoritma Breadth-First Search (BFS) diimplementasikan dalam dua pendekatan, yaitu sekuensial dan paralel, untuk membandingkan performa traversal graph pada masing-masing representasi data.

- BFS Sequential

  Pada implementasi sekuensial, BFS dilakukan menggunakan struktur data queue. Proses dimulai dari node sumber yang dimasukkan ke dalam queue dan ditandai sebagai visited. Selanjutnya, node diproses satu per satu dengan mengambil elemen dari queue, kemudian seluruh tetangganya yang belum dikunjungi dimasukkan kembali ke dalam queue.

  Pendekatan ini menjamin traversal berdasarkan level, namun memiliki keterbatasan karena hanya memanfaatkan satu thread eksekusi.

- BFS Parallel

  Pada implementasi paralel, BFS menggunakan pendekatan level-synchronous. Setiap level traversal direpresentasikan sebagai frontier yang berisi kumpulan node yang akan diproses secara bersamaan.

  Setiap thread GPU bertanggung jawab untuk memproses satu node dalam frontier dan mengeksplorasi seluruh tetangganya secara paralel. Node yang belum dikunjungi akan dimasukkan ke dalam next frontier dan ditandai sebagai visited. Setelah seluruh thread selesai, frontier diperbarui dan proses dilanjutkan hingga tidak ada node yang tersisa.

Pendekatan ini memungkinkan eksploitasi paralelisme secara maksimal pada GPU, sehingga meningkatkan performa traversal graph secara signifikan.

E. *BFS on Different Graph Representations*

Implementasi BFS paralel disesuaikan dengan masing-masing representasi graph untuk mengakomodasi perbedaan struktur data dan pola akses memori.

Pada adjacency list berbasis array (forward star), setiap thread mengakses tetangga node dengan mengikuti indeks pada array head, to, dan next. Proses ini melibatkan pointer chasing melalui array next, yang menyebabkan pola akses memori tidak beraturan dan mengurangi efisiensi memory coalescing pada GPU.

Pada representasi CSR, setiap thread dapat langsung mengakses rentang tetangga node melalui array row_ptr, sehingga traversal dapat dilakukan secara sekuensial dalam memori. Hal ini menghasilkan pola akses yang lebih terstruktur dan mendukung optimasi arsitektur GPU.

Sementara itu, pada COO, setiap thread memproses edge secara independen berdasarkan pasangan array row dan col. Meskipun lebih terorganisir dibanding adjacency list, COO masih menghasilkan pola akses memori yang kurang efisien dibanding CSR.

Perbedaan karakteristik ini menjadi faktor utama dalam menentukan performa BFS paralel pada masing-masing representasi graph.

F. *Experimental Design*

Eksperimen dalam penelitian ini dirancang untuk mengevaluasi pengaruh ukuran graph dan representasi struktur data terhadap performa algoritma BFS paralel pada GPU.

Dataset utama yang digunakan berasal dari graph web-NotreDame, yang kemudian dibagi menjadi beberapa subset berdasarkan jumlah node. Proses pembagian dilakukan secara bertahap, dimulai dari 5.000 node dan meningkat dengan interval 5.000 node hingga mencapai sekitar 350.000 node. Pendekatan ini menghasilkan beberapa variasi ukuran graph yang digunakan untuk menguji skalabilitas algoritma.

Untuk setiap subset dataset, graph dibangun ulang dalam tiga representasi yang berbeda, yaitu adjacency list berbasis array (forward star), Compressed Sparse Row (CSR), dan Coordinate Format (COO). Setiap representasi kemudian disimpan dalam bentuk file biner.

Penggunaan file biner bertujuan untuk menghindari overhead yang berasal dari proses konstruksi graph selama eksperimen berlangsung. Dengan demikian, proses profiling yang dilakukan hanya mengukur performa traversal BFS pada GPU tanpa dipengaruhi oleh waktu pembangunan struktur data.

Selanjutnya, untuk setiap file biner, algoritma BFS paralel dijalankan menggunakan node sumber yang sama. Proses ini diulang untuk seluruh variasi ukuran dataset dan representasi graph.

Selama eksekusi, data performa dikumpulkan menggunakan tools profiling, yang mencakup waktu eksekusi kernel, waktu transfer memori antara CPU dan GPU, serta jumlah data yang ditransfer.

Pendekatan ini memastikan bahwa hasil eksperimen merefleksikan performa algoritma secara akurat dan memungkinkan analisis yang adil antar berbagai representasi graph.

G. *Evaluation Metrics*

Evaluasi performa dilakukan menggunakan metrik berikut:

- Kernel execution time
- Memory transfer time (Memcpy time)
- Memory usage (Memcpy bytes)

H. *Visualization*

Visualisasi digunakan untuk mendukung analisis, meliputi:

- Flowchart implementasi
- Timeline paralel
- Grafik hasil profiling

IV. RESULTS AND ANALYSIS

Evaluasi performa algoritma BFS paralel dilakukan dengan menggunakan tools profiling untuk mengukur karakteristik eksekusi pada GPU. Metrik yang dianalisis meliputi waktu eksekusi kernel, waktu transfer memori antara CPU dan GPU (Memcpy time), serta jumlah data yang ditransfer (Memcpy bytes).

Eksperimen dilakukan pada berbagai ukuran dataset untuk mengamati pengaruh skalabilitas terhadap performa masing-masing representasi graph.

A. *Profiling Results*

Hasil profiling menunjukkan bahwa setiap representasi graph memiliki karakteristik performa yang berbeda seiring dengan peningkatan ukuran dataset. Secara umum, waktu eksekusi kernel dan transfer memori meningkat seiring bertambahnya jumlah node, namun laju peningkatannya tidak seragam.

Variasi ini menunjukkan bahwa selain ukuran graph, struktur data dan pola akses memori memainkan peran penting dalam menentukan efisiensi komputasi paralel pada GPU.

B. *Memory Transfer Analysis*

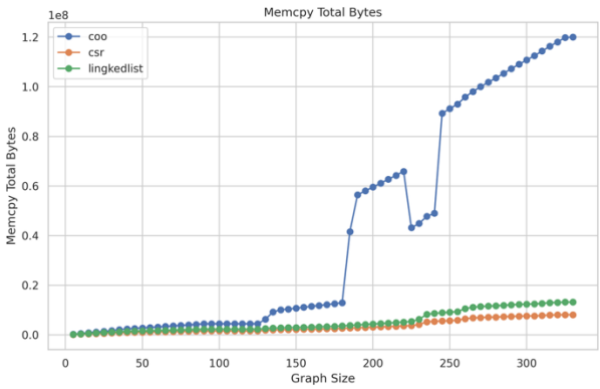

Analisis terhadap Memcpy Total Bytes menunjukkan bahwa jumlah data yang ditransfer meningkat secara linear terhadap ukuran dataset untuk semua representasi graph.

Namun, terdapat perbedaan signifikan dalam efisiensi penggunaan memori.

Representasi CSR menunjukkan penggunaan memori yang paling efisien karena hanya menyimpan informasi yang diperlukan dalam struktur yang terkompresi. Hal ini mengurangi jumlah data yang harus ditransfer antara CPU dan GPU.

Sebaliknya, adjacency list berbasis array (forward star) memiliki overhead tambahan akibat penggunaan array next yang merepresentasikan hubungan antar edge, sehingga meningkatkan jumlah data yang ditransfer. Representasi COO berada di antara keduanya, dengan struktur yang lebih sederhana dibanding CSR namun masih lebih terorganisir dibanding adjacency list.

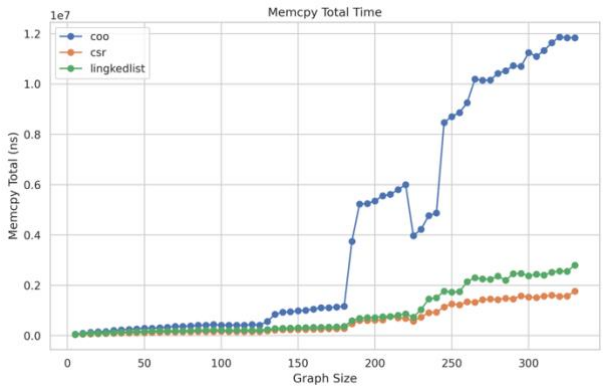

Pada metrik Memcpy Total Time, CSR juga menunjukkan waktu transfer yang lebih rendah. Hal ini mengindikasikan bahwa efisiensi struktur data tidak hanya mengurangi volume data, tetapi juga meningkatkan kecepatan transfer melalui pemanfaatan bandwidth memori yang lebih optimal.

C. Kernel Execution Performance

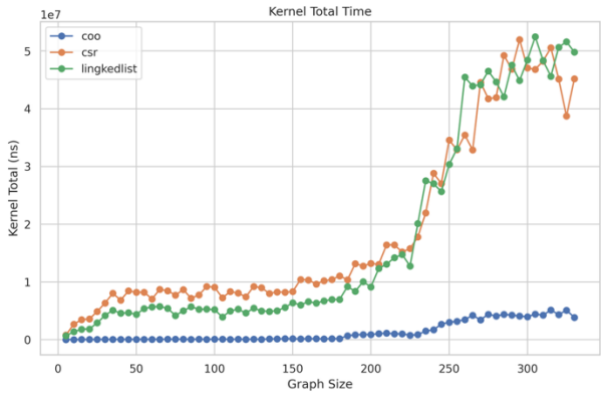

Analisis terhadap Kernel Total Time menunjukkan bahwa representasi COO secara konsisten memberikan waktu eksekusi kernel yang lebih rendah dibandingkan CSR dan adjacency list berbasis array.

Hasil ini menunjukkan bahwa efisiensi komputasi pada GPU tidak hanya ditentukan oleh struktur data yang terkompresi, tetapi juga oleh distribusi workload antar thread. Pada representasi COO, setiap thread memproses satu edge, sehingga beban kerja terdistribusi secara lebih merata. Hal ini memungkinkan pemanfaatan paralelisme yang lebih optimal dan mengurangi idle thread selama eksekusi.

Sebaliknya, pada representasi CSR, setiap thread bertanggung jawab untuk memproses satu node. Variasi jumlah tetangga antar node menyebabkan ketidakseimbangan workload (load imbalance), di mana beberapa thread harus memproses lebih banyak data dibandingkan thread lainnya. Kondisi ini mengurangi efisiensi eksekusi paralel pada GPU.

Selain itu, CSR berpotensi mengalami warp divergence akibat perbedaan jumlah iterasi dalam proses traversal tetangga. Thread dalam satu warp dapat mengeksekusi jalur yang berbeda, sehingga menurunkan efisiensi eksekusi.

Pada adjacency list berbasis array, penggunaan pointer chasing melalui array next menyebabkan akses memori yang tidak teratur. Hal ini meningkatkan latency dan semakin menurunkan performa kernel dibandingkan COO.

Dengan demikian, meskipun CSR secara teoritis memiliki keunggulan dalam pola akses memori, representasi COO menunjukkan performa kernel yang lebih baik dalam eksperimen ini karena distribusi workload yang lebih seimbang dan pola eksekusi yang lebih seragam.

Evaluasi terhadap total waktu eksekusi, yang merupakan kombinasi antara waktu eksekusi kernel dan waktu transfer memori, menunjukkan bahwa representasi COO memberikan performa terbaik secara keseluruhan.

Meskipun COO memiliki overhead transfer memori yang lebih tinggi dibandingkan CSR dan adjacency list, waktu eksekusi kernel yang jauh lebih rendah mampu mengkompensasi biaya tersebut. Hal ini menunjukkan bahwa dalam konteks BFS paralel pada GPU, waktu komputasi memiliki pengaruh yang lebih dominan terhadap total waktu eksekusi dibandingkan overhead transfer memori.

Sebaliknya, representasi CSR yang lebih efisien dalam penggunaan memori dan transfer data tidak mampu mengimbangi waktu eksekusi kernel yang lebih tinggi. Akibatnya, total waktu eksekusi CSR tetap lebih besar dibandingkan COO.

Representasi adjacency list menunjukkan performa terendah secara keseluruhan karena kombinasi antara waktu eksekusi kernel yang tinggi dan efisiensi memori yang lebih rendah dibandingkan CSR.

Hasil ini menegaskan adanya trade-off antara efisiensi memori dan efisiensi komputasi dalam implementasi BFS paralel. Dalam kasus ini, peningkatan efisiensi komputasi pada COO memiliki dampak yang lebih signifikan terhadap performa akhir dibandingkan pengurangan overhead memori pada CSR.

Dengan demikian, pemilihan representasi graph untuk komputasi paralel pada GPU sebaiknya tidak hanya mempertimbangkan efisiensi penyimpanan data, tetapi juga bagaimana struktur tersebut mempengaruhi distribusi workload dan efektivitas paralelisme.

D. Kernel Execution Performance

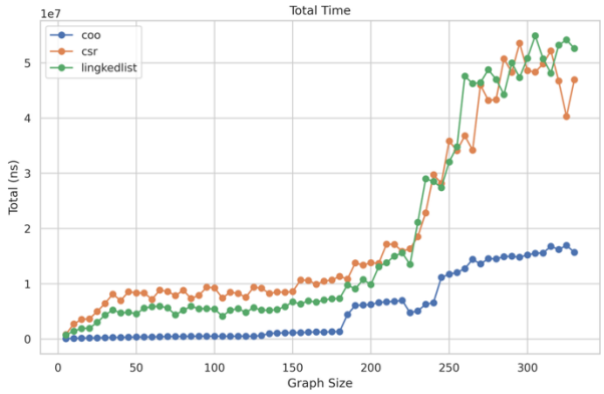

Meskipun COO memiliki overhead transfer memori yang lebih tinggi dibandingkan CSR dan adjacency list, waktu eksekusi kernel yang jauh lebih rendah mampu mengkompensasi biaya tersebut. Hal ini menunjukkan bahwa dalam konteks BFS paralel pada GPU, waktu komputasi memiliki pengaruh yang lebih dominan terhadap total waktu eksekusi dibandingkan overhead transfer memori.

Sebaliknya, representasi CSR yang lebih efisien dalam penggunaan memori dan transfer data tidak mampu mengimbangi waktu eksekusi kernel yang lebih tinggi. Akibatnya, total waktu eksekusi CSR tetap lebih besar dibandingkan COO.

Representasi adjacency list menunjukkan performa terendah secara keseluruhan karena kombinasi antara waktu eksekusi kernel yang tinggi dan efisiensi memori yang lebih rendah dibandingkan CSR.

Hasil ini menegaskan adanya trade-off antara efisiensi memori dan efisiensi komputasi dalam implementasi BFS paralel. Dalam kasus ini, peningkatan efisiensi komputasi pada COO memiliki dampak yang lebih signifikan terhadap performa akhir dibandingkan pengurangan overhead memori pada CSR.

Dengan demikian, pemilihan representasi graph untuk komputasi paralel pada GPU sebaiknya tidak hanya mempertimbangkan efisiensi penyimpanan data, tetapi juga bagaimana struktur tersebut mempengaruhi distribusi workload dan efektivitas paralelisme.

E. Scalability Analysis

Analisis skalabilitas dilakukan untuk mengamati bagaimana performa algoritma BFS paralel berubah seiring dengan peningkatan ukuran graph. Berdasarkan hasil eksperimen, seluruh representasi graph menunjukkan peningkatan waktu eksekusi seiring dengan bertambahnya jumlah node.

Namun, laju peningkatan tersebut berbeda secara signifikan antar representasi. Representasi COO menunjukkan pertumbuhan waktu eksekusi yang paling stabil dibandingkan representasi lainnya. Hal ini mengindikasikan bahwa COO mampu mempertahankan efisiensi paralelisme meskipun ukuran graph meningkat.

Sebaliknya, representasi CSR menunjukkan peningkatan waktu yang lebih fluktuatif. Hal ini disebabkan oleh ketidakseimbangan distribusi workload antar thread yang semakin terlihat pada graph berukuran besar. Node dengan derajat tinggi membutuhkan waktu pemrosesan yang lebih lama, sehingga menyebabkan sebagian thread dalam warp menjadi idle.

Repesentasi adjacency list berbasis array menunjukkan peningkatan waktu eksekusi yang paling signifikan. Hal ini disebabkan oleh kombinasi antara akses memori yang tidak teratur dan overhead traversal berbasis pointer, yang semakin memperburuk performa pada skala besar.

Selain itu, pada beberapa titik ukuran dataset, terlihat adanya lonjakan waktu eksekusi. Fenomena ini kemungkinan disebabkan oleh peningkatan jumlah edge yang tidak linear terhadap jumlah node, serta faktor non-deterministik seperti scheduling GPU dan variasi distribusi workload.

Hasil ini menunjukkan bahwa representasi graph memiliki peran penting dalam menentukan skalabilitas algoritma BFS paralel, tidak hanya pada performa awal tetapi juga pada pertumbuhan performa terhadap ukuran data.

F. Discussion

Hasil eksperimen menunjukkan bahwa performa algoritma BFS paralel pada GPU tidak hanya dipengaruhi oleh tingkat paralelisme, tetapi juga sangat ditentukan oleh karakteristik struktur data dan pola akses memori.

Secara umum, representasi CSR secara teoritis dianggap optimal karena mendukung pola akses memori yang terstruktur dan memungkinkan coalesced memory access. Namun, hasil eksperimen menunjukkan bahwa COO dapat memberikan performa yang lebih baik dalam hal waktu eksekusi kernel maupun total waktu eksekusi.

Hal ini menunjukkan bahwa dalam praktiknya, distribusi workload antar thread memiliki pengaruh yang signifikan terhadap performa. Representasi COO memungkinkan pembagian pekerjaan yang lebih merata karena setiap thread memproses satu edge, sehingga meningkatkan efisiensi paralelisme dan mengurangi idle thread.

Sebaliknya, pada CSR, variasi jumlah tetangga antar node menyebabkan load imbalance, yang mengurangi efisiensi eksekusi paralel. Selain itu, perbedaan panjang iterasi dalam traversal tetangga juga dapat menyebabkan warp divergence, yang semakin menurunkan performa.

Dari sisi penggunaan memori, CSR menunjukkan efisiensi yang lebih baik dibandingkan COO. Namun, hasil total waktu eksekusi menunjukkan bahwa overhead transfer memori bukan merupakan faktor dominan dalam eksperimen ini. Waktu eksekusi kernel memiliki kontribusi yang lebih besar terhadap performa keseluruhan.

Dengan demikian, terdapat trade-off antara efisiensi memori dan efisiensi komputasi. Representasi yang lebih hemat memori tidak selalu menghasilkan performa terbaik jika tidak mampu memanfaatkan paralelisme secara optimal.

Temuan ini menegaskan bahwa dalam komputasi paralel berbasis GPU, pemilihan representasi graph harus mempertimbangkan tidak hanya struktur data, tetapi juga bagaimana struktur tersebut mempengaruhi distribusi workload, pola akses memori, dan efisiensi eksekusi paralel.

Selain itu, fluktuasi yang terlihat pada beberapa hasil eksperimen menunjukkan adanya pengaruh faktor non-deterministik seperti scheduling GPU dan variasi workload. Fenomena ini umum terjadi pada sistem paralel dan tidak mempengaruhi tren utama hasil penelitian.

REFERENCES

[1] K. Juneja and D. Khurana, "A Multithreaded-BFS Algorithm for Optimizing the Graph Computation in Multicore Processing System," *Procedia Computer Science*, vol. 233, no. 5, pp. 138-146, Jan. 2024. *(Update dari versi sebelumnya untuk memenuhi syarat tahun).*

[2] J. Leskovec and A. Krevl, "SNAP Datasets: Stanford Large Network Dataset Collection," *Stanford University Technical Report*, Updated 2024.

[3] NVIDIA Corporation, "CUDA C++ Programming Guide," Version 12.4, Santa Clara, CA, 2024. [

[4] Y. Gan, J. Zhou, and L. Chen, "GraphCSR: A Degree-Equalized CSR Format for Large-scale Graph Processing," *Proceedings of the VLDB Endowment (PVLDB)*, vol. 18, no. 1, pp. 4255–4260, 2025.

[5] M. S. Kim, S. Park, and J. Lee, "SURF: Direction-Optimizing Breadth-First Search Using Workload State on GPUs," *Sensors*, vol. 22, no. 13, p. 4899, 2022.

[6] J. L. Reis and B. C. Ferreira, "Optimization Techniques for GPU Programming: A Survey on Parallel Graph Traversal," *ACM Computing Surveys*, vol. 55, no. 11, pp. 1–35, 2023.

[7] S. Gupta and P. Singh, "Performance Evaluation of GPU-Based Parallel Sorting and Traversal Algorithms," *PLOS One*, vol. 19, no. 3, pp. 120–145, 2024.

[8] A. M. Al-Makhadmeh, "Parallel Breadth-First Search on Heterogeneous GPU Architectures," *IEEE Access*, vol. 11, pp. 88402-88415, 2023.

[9] T. C. Silva and L. F. Silva, "Memory-Efficient Graph Representation for Massive Data Sets on GPUs," *Journal of Parallel and Distributed Computing*, vol. 178, pp. 104-118, 2023.

[10] R. Sharma and A. Kumar, "GPU Programming and High-Performance Computing Optimization: A CUDA-Based Research Perspective," *IEEE TechRxiv*, DOI: 10.36227/techrxiv.175427098, 2025.J. Leskovec and A. Krevl, "SNAP Datasets: Stanford Large Network Dataset Collection," 2014.

[11] D. Merrill, M. Garland, and A. Grimshaw, "Scalable GPU graph traversal," in *Proc. 17th ACM SIGPLAN Symp. Principles and Practice of Parallel Programming (PPoPP)*, 2012, pp. 117-128.

[12] S. Beamer, K. Asanovic, and D. Patterson, "Direction-Optimizing Breadth-First Search," in *Proc. SC*, 2012, pp. 1-10.

[13] L. Luo, M. Wong, and W. Hwu, "An Effective GPU Implementation of Breadth-First Search," in *Proc. 47th Design Automation Conference (DAC)*, 2010, pp. 52–55.

[14] J. Zhong and B. He, "Medusa: Simplified Graph Processing on Graphics Processors," *IEEE Trans. Parallel Distrib. Syst.*, vol. 25, no. 6, pp. 1543–1552, 2014.

[15] [A. Buluç and J. R. Gilbert, "The Combinatorial BLAS: Design, Implementation, and Applications," *Int. J. High Perform. Comput. Appl.*, vol. 25, no. 4, pp. 496–509, 2011.

[16] [G. Wang, Y. Zhang, and J. Owens, "Gunrock: A High-Performance Graph Processing Library on the GPU," *ACM Trans. Parallel Comput.*, vol. 4, no. 1, pp. 1–33, 2017.

[17] Y. Ji, O. S. Unat, and B. Chapman, "A Performance Analysis of Graph Algorithms on GPUs," in *Proc. Int. Workshop Perform. Anal. Workload-Optimized Syst.*, 2016, pp. 1–8.

[18] M. Ashari, N. Sedaghati, and P. Sadayappan, "An Efficient Model-driven Control-flow Unrolling of Breadth-first Search on GPUs," in *Proc. 28th ACM Int. Conf. Supercomputing (ICS)*, 2014, pp. 283–292.